Probleme & offene Fragen — Stand Metaanalyse-Agent

Stand: 05.11.2026, ~21:45 · Thema: „Does melatonin improve sleep onset latency and sleep quality in adults" **Grundlage:** Run 1 (Netzlauf 15:12–19:14), Run (b) Harness-Lauf, Fixtures-Benchmark, Repeat-Lauf Run 2 (seit 19:30, DB `data/research2-…382747.db`, laufend), TODO-Liste `data/bench/todo_gelernte_fehler.md`, Logs unter `data/runs/`.

---

1. Kurzbilanz: erledigt seit dem letzten Stand

Item	Ergebnis	Fundort
1a/1b Poolbarkeits-Gate	Prüft korrekt — Ursache ist die Extraktionstiefe, nicht der Filter	Diagnose im TODO
1c Pooling-Engine	Existiert bereits (`meta/pooling.py`: HKSJ + RVE, `build_analysis`, in `report.py` verdrahtet, Referenztests)	Git-Tree
2a Relevanz-Gate arXiv	4 Fixes (case-insensitive Kategorien, Legacy-Präfixe, ≥2 Treffer für moderne IDs, `sleep_medicine`-Domänengruppe)	lokal, gitignored
2a Tests	`test_topic_gate_arxiv.py`, 5/5 bestanden, Commit `fc5bcdd`, gepusht	Repo
3a-i Vision-Fallback-Trigger	Trigger feuert jetzt auch bei „Zeilen da, aber 0 poolbar" (SE/CI fehlt komplett); 6 neue Tests, Suite **1024 passed / 2 skipped**	Commit `de4cd5c`
4a Biz-Scanner-Selbstwarnung	31 Hypothesen : 2 Befunde als korrektes Früh-Signal dokumentiert, nicht stummgestellt	Vergleichsbericht
Fixtures-Benchmark	recall 1.0 · precision 0.667 · extraction 1.0 · critical_errors 0	`data/bench/fixt/`

---

2. Aktuelle Kernprobleme (nach Schwere)

P1 — Extraktionstiefe blockiert das Pooling (Hauptblocker)

Das Pooling braucht ≥2 Zeilen mit SE oder CI in derselben Outcome-Gruppe. Realität:

DB	Effektzeilen	mit SE	mit CI	poolbar
Run 1 (Melatonin, Netzlauf)	19	1	0	1
Run 2 (Repeat, Stand 21:45)	6 (3 einzig.)	2	1	1 (β 0.198, se 0.021, ci 0.156–0.239, sleep quality)
Run 1 Caffeine ×2	8 / 12	0	0	0
Referenz: Exercise-DB	129	55	55	55
Referenz: Mediterrane-DB	91	38	36	38
Referenz: Kognition-DB	127	27	21	27

Die Engine **kann** SE/CI sauber ziehen (Referenz-DBs beweisen es). Die Caffeine/Melatonin-Läufe bleiben da stehen, wo die Zahlen nur in Diagrammen oder langen Tabellen des PDFs stecken. Run 1 +

Run 2 kombinieren hilft nicht: die Zeilen gehören zu verschiedenen Outcome-Maßen (β vs. HR vs. „other" ohne Wert).

P2 — Vision-Fallback braucht Original-PDFs, die oft fehlen

Der Fallback rasterisiert **nur Original-PDFs**. Die 62 OA-Volltexte im Seeder-Puffer sind XML — für diese Quellen kann die Bildlesung nichts lesen. Da der Trigger erst mit dem Fix von heute Abend überhaupt anspringt, ist der tatsächliche Effekt von P2 noch **unbeobachtet**: Nach dem Run-2-Ende muss der Endvergleich zeigen, für wie viele Quellen der Fix überhaupt angenommen hat.

P3 — Rate-Limits drosseln die Netzabdeckung

OpenAlex/Semantic Scholar sitzen abends dauerhaft im 429/503-Backoff (20–30 min offen), TUDaGPT teilen sich beide Läufe. Der Repeat-Lauf überlebt das mit Backoff (LOW Speed), aber Suchbreite und Tempo verlieren spürbar. Konsequenz: Messergebnisse aus Abend-Läufen unterschätzen die Tages-Performance.

P4 — Vision-Seitenbudget kann knapp werden

`vision_max_pages_per_run = 12`. Sobald der Trigger-Fix greift und viele Quellen Fallback-Lesungen beanspruchen, hat das Budget Nachjustierpotenzial — **nach** geprüften Log-Zahlen entscheiden, nicht blind erhöhen (Kosten).

P5 — Code-Hygienefund am Rande

In `orchestrator.py` existieren korruptierte Kommentare (Zeilen in `_vision_fallback_effects`) und die Datei enthielt bis heute Abend fast nur `CR CR LF`-Zeilenenden (4872/4890), was Tokenizer-Unterschiede zwischen Tools erzeugte. Seit heute auf LF normalisiert (lokal, gitignored). Konsequenz: Reiner Kommentar-Textstaub berührt die Logik nicht, sollte aber beim nächsten Arbeitszug gestutzt werden.

---

3. Offene Fragen (Entscheidungsbedarf)

1. **Endvergleich Run 1 vs. Run 2 (3a-ii):** Steigt die Effekt-/CI-Rate so weit, dass ≥2 poolbare Zeilen zusammenkommen? Wenn **nein** → nächster Hebel ist PDF-Nachschub (P2), nicht ein weiterer Blindlauf.
2. **PDF-Nachschub:** Für welchen Teil der 62 OA-XML-Quellen existiert parallel ein Publisher-PDF über Unpaywall/PMC? Ein Skript kann das prüfen und direkt laden; danach gezielter Extraktionspass — oder sind die Quellen auch dort tabellen-/diagrammlastig?
3. **Merge oder Ersetzen beim Vision-Fallback:** Heute ersetzen Vision-Zeilen die nutzlosen Text-Zeilen (Semantik wie der `not rows`-Pfad). Sollen wir die Text-Zeilen zusätzlich behalten (Dokumentation, nicht poolbar) — oder bleibt es beim Ersetzen (aktuell)?
4. **Meta-Ende der Benchmark-DBs:** Exercise/Mediterrane/Kognition tragen 21–55 poolbare Zeilen. Sollen wir dort **sofort** vollständige Reports inkl. Pooling erzeugen, um die Engine end-to-end zu prüfen — ohne Melatonin?
5. **Referenz-Reviews für den Benchmark:** 20–30 echte publizierte Metaanalysen als Goldstandard bleiben Einkaufsaufgabe. Wann und mit welchem Budget?

6. **Budget P4:** Vision-Seitenbudget erhöhen — nur wenn Log-Daten zeigen, dass 12 Seiten ein echtes Limit für laufende Lesungen sind.

---

4. Empfohlene Reihenfolge

1. **Jetzt das laufende Run 2 auslaufen lassen** — kein Abbruch, kein zweiter Netzlauf gleichzeitig (Rate-Limits).
2. **Nach dem Ende:** Endvergleich (Effekt-/CI-Rate, `eval_run_results.py` auf `research2-…db`) + prüfen, ob der Report einen gepoolten Effekt hat.
3. **Danach entscheiden:** poolbar? → fertig. Nicht poolbar? → PDF-Nachschub (Frage 2), gezielter Extraktionspass, dann neuer Lauf — nicht vor dem Fix blind einen dritten Melatonin-Lauf.
4. **Parallel ohne Risiko:** Meta-Reports aus den befüllten DBs erzeugen (Frage 4).

---

5. Artefakte in diesem Bericht

- TODO mit allen Items: `data/bench/todo_gelernte_fehler.md`
- Vergleichsbericht Run 1: `data/bench/lauf_vergleich_20261105.md`
- Zwischenstand Run 2: `data/bench/net_run2_zwischenstand.md`
- Logs: `data/runs/melatonin_net_run{1,2}.log`, `melatonin_harness_run1.log`
- Reports als PDF: `data/reports/20261105-18{13,14}-*.pdf`
- Fixtures-Benchmark: `data/bench/fixt/benchmark_smoke.json`