Briefing: Metaanalyse-Agent — Stand und Umsetzungsauftrag

Adressat: ein leistungsfähiges Planungsmodell. **Zweck:** Dieses Dokument beschreibt den verifizierten Stand des Projekts, die bereits getroffenen Entscheidungen, die gemessenen Grenzen und die offenen Arbeitspakete so vollständig, dass daraus ein konkreter Umsetzungsplan (Phasen, Dateien, Tests, Risiken, Aufwand) erstellt werden kann.

Was hier NICHT verlangt wird: Code. Verlangt wird ein Plan, der auf die unten genannten Dateien, Befehle und Akzeptanzkriterien Bezug nimmt. Jede Behauptung im Plan muss auf eine prüfbare Quelle (Test, Log, DB-Abfrage, Skriptlauf) verweisen.

---

1. Das Projekt in drei Sätzen

Ein autonomer Metaanalyse-Agent recherchiert zu einer Forschungsfrage selbst im Web, liest wissenschaftliche Volltexte, extrahiert Effektmaße **wörtlich aus der Quelle** (Verbatim-Kontrakt), bewertet Bias-Risiken, poolt statistisch LLM-frei und erzeugt einen zitierfähigen PDF-Bericht. Die Statistik ist deterministisch und reproduzierbar; kein Sprachmodell rechnet eine Zahl. Die Mechanik ist gebaut und getestet — der Engpass ist die **Ausbeute an poolbaren Effekten je Endpunkt**.

2. Qualitätsinvarianten (nicht verhandelbar)

Diese Regeln sind der Kern des Projekts. Ein Plan, der sie verletzt, ist unbrauchbar, auch wenn er schneller wäre.

1. **Verbatim-Kontrakt.** Jede gespeicherte Zahl trägt ein Zitat mit Zeichenspan, das gegen den Quelltext geprüft wurde (`quote_start >= 0`). Ohne verifizierten Beleg keine Zeile, keine Ausnahme.
2. **Keine erfundenen Werte.** Jede Zahl im Bericht stammt aus DB, Log oder einer nachrechenbaren Quelle. Schätzungen werden als Schätzungen markiert.
3. **Doppel-Extraktion wird nie gemittelt.** Zwei abweichende Lesungen ergeben `disputed = 1` und fliegen aus dem Pool, nicht in den Mittelwert.
4. **Ein Review ist keine Studie.** Aggregat-Zeilen (Metaanalysen, gepoolte Werte) sind keine Primärstudien und dürfen nicht mitgepoolt werden.
5. **k = 1 ergibt keine gepoolte Zahl.** Der Pool verweigert sie und sagt es.
6. **Abhängigkeit zählt einmal.** Gleiche DOI, gleiche Quelle, gleiche `study_id` oder gleiche belegte Kohorte kollabieren auf die präziseste Zeile; die verdrängten Zeilen werden mit Grund ausgewiesen.
7. **Gates sind deterministisch und dokumentiert.** Design-, Demografie-, Median-, SEM/SE- und Tabellenrest-Gates sind Konstanten im Code, keine Modellentscheidung.
8. **Geschützte Dateien.** `research_agent/orchestrator.py`, `research_agent/meta/extraction.py` und `research_agent/meta/pooling.py` sind gitignored: lokal ändern erlaubt, **niemals committen**. Für sie gibt es `*_PRIVAT.md`-Beschreibungen im Repo.

3. Architektur (Ist-Zustand)

Baustein	Pfad	Aufgabe	Zustand
Orchestrator	`research_agent/orchestrator.py` (geschützt)	Phasen Planning … Updating, Run-Resume	läuft
Suche	`research_agent/research/sources.py`	Europe PMC, OpenAlex, Crossref, Semantic Scholar	läuft, rate-limit-anfällig
Volltext	`research_agent/research/fulltext.py`, `jats_tables.py`	XML/PDF-Layout, Tabellen	läuft
Screening	`research_agent/meta/screening.py`	Include/Exclude mit Begründung	lückenhaft
Zielmaße	`research_agent/meta/targets.py`	Frage → Outcome-Vokabular, Kanonisierung	fertig
Extraktion	`research_agent/meta/extraction.py` (geschützt)	LLM-Lesung + Verbatim-Prüfung	fertig
Leser (deterministisch)	`meta/effect_columns.py`, `arm_level.py`, `arm_text.py`, `arm_change.py`	Tabellen, Arme, Fließtext, Veränderungswerte	fertig, Ausbeute gering
Outcome-Namen	`meta/outcome_labels.py`	deterministische Normalisierung für Gruppierung	fertig
Pooling	`meta/pooling.py` (geschützt)	HKSJ, REML, RVE, Egger, Leave-one-out, Subgruppen	fertig
Bias	`meta/risk_of_bias.py`, `rob2_signalling.py`, `grade.py`	RoB 2, GRADE	läuft
Bericht	`report.py`, `report_pdf.py`	Markdown → PDF (Edge headless)	läuft
Dashboard	`dashboard/`	localhost-WebUI, keine Auth	läuft
Benchmark	`evals/meta_benchmark.py`	Fixtures-Benchmark	nur synthetisch

4. Verifizierter Stand (Messwerte, keine Schätzungen)

4.1 Testsuite

```
1146 passed, 2 skipped, 0 failed   (401,72 s, Gesamtsuite)
158 passed                          (Meta-Kern: Leser, Zielmaße, Outcome-Namen)
```

In einer ersten Messung war ein Test rot: das Gruppenlabel `General cognitive ability [hedges_g]` wurde als `general cognitive ability [hedges_g]` ausgegeben. Ursache: die Outcome-Normalisierung überschrieb den Anzeigenamen. Behoben durch eine Ziel-Label-Zuordnung in `pooling.py` (geschützt, daher lokal, nicht committet). **Konsequenz für den Plan:** Änderungen an `pooling.py` müssen lokal getestet und in `*_PRIVAT.md` dokumentiert werden, sie erscheinen nie im Diff.

4.2 Korpus (Frage: Melatonin vs. Placebo, Einschlaflatenz)

Kennzahl	Wert
Europe-PMC-Treffer	1.067
davon mit PMCID	1.059
XML erfolgreich geladen	**1.056** (3 × HTTP 500: `PMC7163627`, `PMC8959415`, `PMC9554922`)
Dokumente mit mindestens einem „mean ± SD"	426 von 1.056

4.3 Ausbeute der vier Leser auf diesem Korpus

Leser	Eingabe	gespeicherte Zeilen	Dokumente	Gruppen	k ≥ 2
Effektspalten (Tabellen)	42.396 Zeilen	513	18	154	0
Arm-Rechner (Tabellen)	42.771 Zeilen	8	4	8	0
Fließtext-Arme	315.857 Sätze	1	1	1	0
Veränderungswerte	315.857 Sätze	1	1	1	0

Vereinigung aller vier Leser: **162 Gruppen**. Der einzige scheinbare k = 2 (`low`) ist als Artefakt belegt: eine OR-Zeile (`10.1002/fsn3.1050`) und eine Tertilzeile (`10.1186/s12889-026-26824-4`) landeten in derselben Gruppe; nach Filter auf Effekttyp g bleibt k = 1. Von den 513 Effektzeilen sind nur **5 SOL-artig** (197 beta, 160 OR, 112 mean_diff, 15 g, 15 smd, 12 RR, 2 HR).

4.4 End-to-End-Läufe (05.11.2026, je ca. 4 h)

Kennzahl	Netzlauf	Harness-Lauf
Quellen	127	112
registrierte Studien	26	34
Volltext vorhanden	9 (35 %)	20 (59 %)
Effekte extrahiert	14	21
davon `mean_diff`	3	16
davon mit Konfidenzintervall	0	2

Beide Läufe erzeugten PDF-Berichte. Der Netzlauf zeigt den Kern des Problems: ohne Volltexte bleiben fast nur verbale, nicht poolbare Befunde.

4.5 Der Saat-Korpus-Versuch (gescheitert, und zwar an der Paywall)

Die einzige publizierte Metaanalyse zur Frage — *Sleep Medicine* 2020, DOI `10.1016/j.sleep.2019.02.017`, PMID 31982807 — ist **nicht offen** (kein PMCID, `isOpenAccess = N`). Sie nennt im Abstract: 7 Trials, 387 Teilnehmer, SOL MD −0,36 h (95 %-CI −0,49 bis −0,24), SOT −0,62 h (−0,80 bis −0,45), DLMO −0,82 h (−1,23 bis −0,41), TST +0,38 h.

Aus ihrer Referenzliste (46 Einträge, ohne DOIs) wurden 8 Trial-Kandidaten extrahiert, 8 von 8 DOIs aufgelöst, dann PMC-Zuordnung:

- **7 von 8 ohne PMC-Volltext** (Europe-PMC-Titelsuche und NCBI-ID-Konverter stimmen überein),

- 1 PMCID (`PMC5872230`) — eine Langzeit-Follow-up-Studie, die die Metaanalyse vermutlich ausgeschlossen hat,
- Lauf aller Leser auf diesem Dokument: **0 Zeilen** (23 + 1 + 2 Ablehnungen).

Ergebnis: der Saat-Weg liefert k = 0, und die Schranke ist der Zugang, nicht die Extraktion. Der offene Korpus enthält die Studien nicht, weil sie nicht offen sind — ein Negativbefund aus ihm ist ein Befund über die offene Teilmenge, nicht über die Literatur.

5. Die vier Blocker (in dieser Reihenfolge)

B1 — Ausbeute je Endpunkt. 42.396 Tabellenzeilen ergeben 513 Effektzeilen, aber nur 5 SOL-artige und nach Effekttyp-Filter k = 0. Es ist unbekannt, an welcher Filterstufe die Masse verloren geht (Tabellenerkennung? Spaltenpaar? Gate? Outcome-Zuordnung?). Ohne dieses Wissen ist jede weitere Optimierung Raten.

B2 — Keine Referenzvalidierung. Pooling, g↔MD-Umrechnung und Heterogenitätsschätzer sind gegen synthetische Fixtures und Unit-Tests geprüft, aber nie gegen ein veröffentlichtes gepooltes Ergebnis. Es gibt keinen Beleg, dass der Agent bei bekannter Wahrheit dasselbe herausbekommt.

B3 — Screening/Relevanz-Gate. Im Harness-Lauf (05.11.) nahm der Agent themenfremde arXiv-Quellen auf (Gesichtsmimik-Erkennung, Gruppentheorie, N-Körper-Code). Das Gate filterte sie erst später; eine Quelle blieb bis zum Ausschluss unter Schwelle sichtbar.

B4 — Zugang zu geschlossener Literatur. Sieben RCTs hinter Paywall. Ohne Bibliothekszugang oder manuelle Erfassung ist diese Evidenzbasis für den Agenten nicht erreichbar; die Frage muss entweder anders zugeschnitten oder die Tabelle von Hand erfasst werden.

6. Bereits entschieden (nicht neu verhandeln)

1. **Zwei Change-Modelle:** `reported` (Veränderung ± SD im Satz → g exakt, ρ irrelevant, `rho = null`) und `prepost` (`SD_change = sqrt(SD_pre² + SD_post² − 2ρ·SD_pre·SD_post)`), primär ρ = 0,5 offengelegt (`rho_assumed: true`) plus Sensitivitätsgrid 0,0/0,3/0,5/0,7/0,9.
2. **Outcome-Gruppierung** über normalisierte Namen plus geprüfte Synonymtabelle; keine Ähnlichkeitsheuristik. Zielmaß-Wortlaut bleibt Anzeigename.
3. **Pooling/2:** adjustiert vs. unadjustiert und verschiedene Follow-up-Zeitpunkte werden nie in einen Pool gemischt; unbekannte Zustände bilden einen eigenen, markierten Pool.
4. **Hartung-Knapp-Sidak als Standard**, Fixed-Effect nur als Vergleichsspalte, Prediction Interval erst ab k ≥ 3.
5. **k-Gate für Moderatoren:** Subgruppen unter k = 3 tragen keine Q-between-Aussage.
6. **Netz-Budget:** höchstens 2–3 Läufe je Untersuchungsfrage, kein Lauf ohne ausdrückliche Freigabe, vorher Telemetrie des letzten Laufs auswerten.

7. Auftrag: Arbeitspakete mit Akzeptanzkriterien

Der Plan soll diese fünf Pakete in eine Reihenfolge bringen, Aufwand und Risiko schätzen und für jedes Paket Dateien, Tests und Abbruchkriterien benennen.

A — Ausbeute-Funnel messen (Voraussetzung für alles Weitere)

Ziel: für den SOL-Korpus eine Tabelle „1.056 Dokumente → n Tabellen → n Zeilen → n Kandidaten → n gespeicherte Zeilen → n poolbare Zeilen", jeweils mit Ablehnungsgrund und Anzahl. Heute existieren nur die Endpunkte dieser Kette.

Akzeptanz: ein Skript, das den Funnel reproduzierbar ausgibt; jede Stufe mit Zahl und Grund; das Ergebnis zeigt, welche **eine** Stufe den größten Verlust verursacht. Kein Netzzugriff nötig (XML liegt lokal).

Verifikation: Skriptlauf auf `data/bench/sol/manifest_all.json`, Ausgabe als JSON + Markdown, Zahlen gegen die bestehenden Befunde (513 Zeilen) konsistent.

B — Referenzdatensatz mit bekannter Wahrheit

Ziel: sieben Zeilen (SOT/SOL je Arm, n, SD) der Kinder-Metaanalyse als Referenz erfassen, k = 7 per Konstruktion, dann Pooling und g↔MD-Umrechnung gegen SOL −0,36 h (−0,49 bis −0,24) prüfen.

Akzeptanz: Referenzdatei mit Quelle je Zahl (Tabelle/Seite), als **manuell erfasst** markiert; ein Vergleichslauf, der die Abweichung des Agenten zur publizierten Schätzung beziffert; Abweichung erklärt oder als offen benannt.

Risiko: ohne Zugang zur Tabelle nicht durchführbar — dann muss der Plan eine Alternativquelle (offenes Referenz-Review) benennen.

C — Tabellenlese-Pfad härten

Ziel: erklären, warum aus 42.396 Tabellenzeilen nur 513 Effektzeilen werden, und die größten deterministischen Verluste beheben (Spaltenerkennung, Einheiten, „mean (SD)"-Varianten, Mehrzeilen-Köpfe).

Akzeptanz: Vorher/Nachher-Zahlen auf demselben Korpus; kein Rückgang der bestehenden Tests; jede Lockerung eines Gates mit Begründung und einem Fall, den sie rettet — nie pauschal.

D — Screening gegen Thementrift

Ziel: das Relevanz-Gate so schärfen, dass themenfremde Quellen vor der Aufnahme abgelehnt werden, mit Begründung und ohne die Trefferquote echter Studien zu senken.

Akzeptanz: gemessene Precision/Recall auf einem annotierten Satz (die bestehenden Läufe liefern die Positiv- und Negativfälle), Vorher/Nachher ausgewiesen.

E — Bericht: Ehrlichkeit über k

Ziel: der Bericht muss bei k = 1 oder k = 0 explizit sagen, dass keine gepoolte Zahl existiert, und die Coverage-Zeile („40 gelesen, 4 zum Zielmaß") prominent zeigen.

Akzeptanz: ein Bericht aus einem Lauf mit k = 1 enthält keinen Satz, der wie ein gepooltes Ergebnis klingt; PRISMA-Zahlen stimmen mit der DB überein.

8. Randbedingungen für den Plan

- **Keine Netzkäufe ohne Freigabe.** Tests und Funnel-Analysen laufen offline auf `data/bench/sol/xml/`.
- **Geschützte Dateien** (Abschnitt 2, Punkt 8) dürfen lokal geändert, aber nicht committet werden; der Plan muss sagen, wie deren Änderungen dokumentiert und getestet werden.
- **Secrets** niemals in Code, Chat oder Commit; `.env` wird nicht gelesen.
- **Commits** klein und thematisch, Footer: `Generated with Codebuff` / `Co-Authored-By: Codebuff <noreply@codebuff.com>`.
- **Jeder Schritt hinterlässt ein Artefakt** (Skript, JSON, Markdown) plus Commit.
- **Keine Zahlen ohne Quelle.** Im Plan jede Aufwandsschätzung als Schätzung markieren.

9. Was der Plan enthalten soll

1. **Reihenfolge und Abhängigkeiten** der Pakete A–E, mit Begründung, warum diese Reihenfolge und nicht eine andere.
2. **Je Paket:** betroffene Dateien, neue Tests (Name + was sie prüfen), Verifikationsbefehl, Akzeptanzkriterium, geschätzter Aufwand in Sitzungen, Risiko und Abbruchkriterium.
3. **Messgrößen**, an denen Fortschritt erkennbar ist (z. B. poolbare Zeilen je Endpunkt, k je Endpunkt, Abweichung zum Referenzdatensatz).
4. **Was bewusst nicht getan wird** und warum.
5. **Offene Fragen an den Menschen**, maximal fünf, jede mit der Information, die ohne Antwort fehlt.

10. Datenlage (Pfade)

Inhalt	Pfad
Korpus-Manifest (1.059)	`data/bench/sol/manifest_all.json`
XML-Volltexte (1.056)	`data/bench/sol/xml/` (gitignored)
Effektzeilen DB	`data/bench/sol/direct_all.db`
Arm-/Text-/Change-DBs	`data/bench/sol/arm_all.db`, `text_arms.db`, `change_arms.db`
Befunde	`data/bench/sol/abschlussbericht_20261107.md`, `seed_meta_befund_20261107.md`
Seed-Versuch	`data/bench/sol/seed_*.json`, `seed_xml/`
Stand/Reifegrad	`data/bench/stand_20261107.md`
Lauf-Auswertungen	`data/bench/net_run_final.md`, `harness_run_final.md`
Testlog	`data/runs/pytest_full_20261107b.log`

11. Reproduktion (Befehle)

```
export PYTHONIOENCODING=utf-8
.venv/bin/python.exe -m pytest research_agent/tests -q
.venv/bin/python.exe scripts/convert_text_arms_xml6.py \
  --manifest data/bench/sol/manifest_all.json \
```

```
  --xml-dir data/bench/sol/xml --db data/bench/sol/text_arms.db
.venv/bin/python.exe scripts/convert_change_arms_xml6.py \
  --manifest data/bench/sol/manifest_all.json \
  --xml-dir data/bench/sol/xml --db data/bench/sol/change_arms.db
.venv/bin/python.exe scripts/pool_direct_effects_xml6.py
```

12. Ein Satz, der den Auftrag zusammenfasst

Der Agent kann alles außer dem einen, worauf es ankommt: aus einem großen offenen Korpus genug belegte Effekte je Endpunkt herausziehen, dass k ≥ 2 entsteht — plane zuerst die Messung dieses Verlusts, dann die Behebung, dann die Validierung gegen eine bekannte Wahrheit.